

Cấu trúc tổng thể của CAFE

Hình: Khung tổng quan của hệ thống CAFE (Cluster and Aggregate). Đầu vào là tập N ảnh probe, lần lượt qua ba thành phần chính – Style Input Maker (SIM), Cluster Network (CN) và Aggregation Network (AGN) – để sinh ra một vector đặc trưng khuôn mặt hợp nhất cuối cùng ¹ ² .

CAFE là framework hai giai đoạn nhằm hợp nhất một tập lớn các ảnh probe thành một đặc trưng duy nhất cho nhận dạng khuôn mặt ¹ . Tổng quan dữ liệu luồng như sau (Hình trên): - **Đầu vào (Probe):** Tập N ảnh (kích thước $H \times W \times 3$). Mỗi ảnh được đưa qua mạng trích xuất đặc trưng (backbone) để thu được: vector đặc trưng nhận dạng $\mathbf{f}_{i \in \{1, \dots, N\}} \in \mathbb{R}^D$ (ví dụ $D=512$) và ma trận đặc trưng trung gian $\mathbf{F}_{i \in \{1, \dots, N\}} \in \mathbb{R}^{C \times H' \times W'}$.

- **Style Input Maker (SIM):** Nhận mỗi ma trận $\mathbf{F}_{i \in \{1, \dots, N\}}$, SIM tính vector thông tin style $\mathbf{s}_{i \in \{1, \dots, N\}} \in \mathbb{R}^d$ bằng cách lấy trung bình μ và độ lệch chuẩn σ theo từng kênh của $\mathbf{F}_{i \in \{1, \dots, N\}}$ ³ . Vector $\mathbf{s}_{i \in \{1, \dots, N\}}$ (chiều d) có thể được ghép thêm embedding của chuẩn (norm) của $\mathbf{f}_{i \in \{1, \dots, N\}}$ ³ . Kết quả là N vector style $\mathbf{S} = \{\mathbf{s}_1, \dots, \mathbf{s}_N\}$.

- **Cluster Network (CN):** CN nhận cặp $(\mathbf{f}_{i \in \{1, \dots, N\}}, \mathbf{s}_{i \in \{1, \dots, N\}})$ của N ảnh. Nó dùng M truy vấn toàn cục (các tâm cụm học được) để tính ma trận phân cụm $\mathbf{A} \in \mathbb{R}^{M \times N}$ (soft assignment) bằng cách so $\mathbf{s}_{i \in \{1, \dots, N\}}$ với M tâm cụm rồi Softmax theo cột ¹ ² . Ma trận \mathbf{A} cho biết mức độ mỗi ảnh được gán vào từng cụm. Sau đó CN tạo ra M vector đặc trưng cụm $\mathbf{C}_{j \in \{1, \dots, M\}} \in \mathbb{R}^D$ và M vector style cụm $\mathbf{X}_{j \in \{1, \dots, M\}} \in \mathbb{R}^d$, trong đó mỗi $\mathbf{C}_{j \in \{1, \dots, M\}}$ là tổng tuyến tính của các $\mathbf{f}_{i \in \{1, \dots, N\}}$ thuộc cụm j , và mỗi $\mathbf{X}_{j \in \{1, \dots, M\}}$ là tổng tuyến tính của các $\mathbf{s}_{i \in \{1, \dots, N\}}$ ¹ .

- **Aggregation Network (AGN):** AGN nhận M cặp $(\mathbf{C}_{j \in \{1, \dots, M\}}, \mathbf{X}_{j \in \{1, \dots, M\}})$ từ CN và dùng một MLP-Mixer để học mối quan hệ giữa các cụm. AGN sinh ra vector trọng số $\mathbf{w} \in \mathbb{R}^M$ cho mỗi cụm ⁴ . Cuối cùng, vector đặc trưng hợp nhất $\mathbf{f} \in \mathbb{R}^D$ được tính bằng tổng có trọng số: $\mathbf{f} = \sum_{j=1}^M \mathbf{w}_j \mathbf{C}_j$ ⁴ . Đầu ra của toàn hệ thống là vector \mathbf{f} dùng cho nhận dạng.

Kết hợp lại, CAFE chia quy trình feature fusion thành ba thành phần riêng biệt. Luồng dữ liệu cụ thể có thể tóm tắt như sau:

- **Đầu vào:** Tập ảnh probe $\{I_1, \dots, I_N\}$. Mỗi ảnh đầu tiên qua mạng nhận dạng khuôn mặt (backbone) để lấy đặc trưng $\mathbf{f}_{i \in \{1, \dots, N\}} \in \mathbb{R}^D$ và các đặc trưng trung gian $\mathbf{F}_{i \in \{1, \dots, N\}} \in \mathbb{R}^{C \times H' \times W'}$.
- **SIM:** Nhận $\mathbf{F}_{i \in \{1, \dots, N\}}$, tính vector style $\mathbf{s}_{i \in \{1, \dots, N\}} = \mathbf{W} \cdot [\mu(\mathbf{F}_{i \in \{1, \dots, N\}}); \sigma(\mathbf{F}_{i \in \{1, \dots, N\}})]$ (cộng thêm embedding của $\|\mathbf{f}_{i \in \{1, \dots, N\}}\|$) ³ . Đầu ra của SIM là tập vector style $\mathbf{S} = (\mathbf{s}_1, \dots, \mathbf{s}_N)$ (Mỗi $\mathbf{s}_{i \in \{1, \dots, N\}} \in \mathbb{R}^d$).
- **CN:** Nhận $(\mathbf{f}_{i \in \{1, \dots, N\}}, \mathbf{s}_{i \in \{1, \dots, N\}})_{i=1..N}$, sử dụng M truy vấn $Q_{j \in \{1, \dots, M\}}$ để tính ma trận $\mathbf{A} \in \mathbb{R}^{M \times N}$ (công thức attention sửa đổi như trong (2)-(3) ⁵ ⁶). Từ \mathbf{A} , CN tạo ra hai ma trận: $\mathbf{C} \in \mathbb{R}^{M \times D}$ (tập M vector $\mathbf{C}_{j \in \{1, \dots, M\}}$) và $\mathbf{X} \in \mathbb{R}^{M \times d}$ (M vector $\mathbf{X}_{j \in \{1, \dots, M\}}$), với $\mathbf{C}_{j \in \{1, \dots, M\}} = (\sum_{i \in \{1, \dots, N\}} \mathbf{A}_{i,j} \mathbf{f}_i) / \sum_{i \in \{1, \dots, N\}} \mathbf{A}_{i,j}$ và tương tự cho $\mathbf{X}_{j \in \{1, \dots, M\}}$.
- **AGN:** Nhận \mathbf{C}, \mathbf{X} (kích thước $M \times (D+d)$), qua MLP-Mixer sinh trọng số $\mathbf{w} \in \mathbb{R}^M$ ⁴ . Tính vector $\mathbf{f}_{\text{fusion}} = \sum_{j=1}^M \mathbf{w}_j \mathbf{C}_j$. Đầu ra là vector đặc trưng hợp nhất $\mathbf{f}_{\text{fusion}} \in \mathbb{R}^D$.

Style Input Maker (SIM)

SIM là mạng phụ trích xuất thông tin kiểu ảnh (style) từ mỗi ảnh mà không liên quan đến nhận dạng. Đầu vào của SIM là ma trận đặc trưng trung gian $F_{i \in \mathbb{R}^{C \times H \times W}} \in \mathbb{R}^{C \times H \times W}$ thu được từ backbone. SIM tính toán giá trị trung bình μ và độ lệch chuẩn σ của $F_{i \in \mathbb{R}^{C \times H \times W}}$ theo từng kênh, rồi dùng ma trận trọng số học được để biến đổi thành vector style $s_{i \in \mathbb{R}^d}$ ³. Kết quả bao gồm thông tin về độ sáng, độ tương phản, chất lượng ảnh, độ xoay, v.v., vốn đã bị loại bỏ khỏi vector nhận dạng $f_{i \in \mathbb{R}^d}$ do mạng FR được huấn luyện nhận dạng chỉ quan tâm đến ID. Ngoài ra, SIM còn nhúng chuẩn $||f_{i \in \mathbb{R}^d}||$ (theo dạng sinusoidal) vào $s_{i \in \mathbb{R}^d}$ để đánh giá độ tin cậy của ảnh³. - **Đầu vào:** Ma trận $F_{i \in \mathbb{R}^{C \times H \times W}}$ (kiểu float) kích thước $C \times H \times W$.

- **Đầu ra:** Vector style $s_{i \in \mathbb{R}^d} \in \mathbb{R}^d$ (độ dài d).

Cluster Network (CN)

CN dùng cơ chế attention sửa đổi để gom nhóm N vector đầu vào vào M cụm cố định. Đầu vào của CN là bộ N vector nhận dạng $f_{i \in \mathbb{R}^D} \in \mathbb{R}^D$ và N vector style $s_{i \in \mathbb{R}^d} \in \mathbb{R}^d$. Bên trong, CN có M truy vấn toàn cục $Q_{j \in \mathbb{R}^d} \in \mathbb{R}^d$ (học được chung cho mọi probe)⁷. CN tính ma trận affinities $Q \cdot S^T$ rồi áp dụng Softmax theo cột để thu ma trận phân cụm $A \in \mathbb{R}^{M \times N}$ ⁷.
¹ Từ A , CN tạo ra M vector cụm $C_{j \in \mathbb{R}^D} \in \mathbb{R}^D$ và M vector style cụm $X_{j \in \mathbb{R}^d} \in \mathbb{R}^d$ bằng tổng cộng tuyến tính: mỗi $C_{j \in \mathbb{R}^D} = (\sum_{i \in \mathbb{R}^D} A_{j,i} f_{i \in \mathbb{R}^D}) / \sum_{i \in \mathbb{R}^D} A_{j,i}$, tương tự với $X_{j \in \mathbb{R}^d}$ từ $s_{i \in \mathbb{R}^d}$ ¹. Do đó, số lượng đầu ra của CN luôn cố định M cụm, bất kể N thay đổi². - **Đầu vào:** N vector $f_{i \in \mathbb{R}^D} \in \mathbb{R}^D$ và N vector $s_{i \in \mathbb{R}^d} \in \mathbb{R}^d$.

- **Đầu ra:** Ma trận phân cụm $A \in \mathbb{R}^{M \times N}$, M vector $C_{j \in \mathbb{R}^D} \in \mathbb{R}^D$ và M vector $X_{j \in \mathbb{R}^d} \in \mathbb{R}^d$ ($j=1..M$)¹².

Aggregation Network (AGN)

AGN kết hợp M vector cụm thành một vector duy nhất. Đầu vào của AGN là tập M cặp $(C_{j \in \mathbb{R}^D}, X_{j \in \mathbb{R}^d})$ (mảng kích thước $M \times (D+d)$). AGN sử dụng cấu trúc MLP-Mixer để lan truyền thông tin giữa các cụm. Đầu tiên, nó biểu diễn M vector này thành một ma trận rồi xuất ra vector $w \in \mathbb{R}^M$ biểu diễn “tầm quan trọng” của mỗi cụm⁴. Cuối cùng, vector đầu ra $f \in \mathbb{R}^D$ được tính bằng tổng có trọng số: $f = \sum_{j=1..M} w_{j \in \mathbb{R}^M} \cdot C_{j \in \mathbb{R}^D}$. Giá trị w được xác định sao cho $\sum_{j \in \mathbb{R}^M} w_{j \in \mathbb{R}^M} = 1$ (qua Softmax) để f là trung bình có trọng số của các cụm. Kết quả f là vector đặc trưng cuối cùng phục vụ tác vụ nhận dạng khuôn mặt.

- **Đầu vào:** M vector $C_{j \in \mathbb{R}^D} \in \mathbb{R}^D$ và M vector $X_{j \in \mathbb{R}^d} \in \mathbb{R}^d$.

- **Đầu ra:** Vector hợp nhất $f \in \mathbb{R}^D$ và vector trọng số cụm $w \in \mathbb{R}^M$ ⁴.

Mỗi thành phần trên đóng vai trò rõ ràng trong pipeline: SIM trích xuất thông tin style (độc lập với ID), CN gom nhóm đầu vào thành M đặc trưng trung gian cố định, và AGN tổng hợp các đặc trưng đó thành một biểu diễn cuối cùng. Cách thiết kế này cho phép CAFace xử lý hiệu quả các tập probe rất lớn và duy trì bất biến với thứ tự đầu vào⁸⁹.

Tài liệu tham khảo: Các thông tin trên được trích từ bài báo gốc CAFace¹²³⁴.

¹ ² ³ ⁴ ⁵ ⁶ ⁷ ⁸ ⁹ [2210.10864] Cluster and Aggregate: Face Recognition with Large Probe Set

<https://arxiv.org/html/2210.10864>